

# 程序作业



曾燎原 浙江工业大学

邮箱: zengly@zjut.edu.cn

致谢: 本教案内容取自北京大学文再文教授的最优化书籍

图像去噪问题

LASSO 问题

逻辑回归问题

程序作业

假设用  $x$  表示一幅真实图像，它是一个  $m \times n$  维的矩阵，其中  $x_{ij}$  代表图像在划定的位置  $(i, j)$  处的灰度值。用  $y$  表示图像  $x$  受到噪声干扰后的图像，即

$$y = x + e,$$

这里假设  $e \in \mathbb{R}^{m \times n}$  是高斯白噪声。为了从有噪声的图像  $y$  中还原原始图像  $x$ ，利用 Tikhonov 正则化的思想建立如下优化模型：

$$\min_{x \in \mathbb{R}^{m \times n}} f(x) = \frac{1}{2} \|x - y\|_F^2 + \lambda (\|D_1 x\|_F^2 + \|D_2 x\|_F^2) \quad (1)$$

其中  $D_1 x, D_2 x$  分别对  $x$  在水平方向和竖直方向上做向前差分，即

$$(D_1 x)_{ij} = \frac{1}{h} (x_{i+1,j} - x_{ij}), \quad (D_2 x)_{ij} = \frac{1}{h} (x_{i,j+1} - x_{ij})$$

其中  $h$  为给定的离散间隔。

模型(1)由两项组成:

- ▶ 第一项为保真项, 即要求原始图像  $x$  和带噪声的图像  $y$  不要相差太大. 由于假设了噪声是高斯白噪声, 此时通常使用矩阵的  $F$  范数

$$\|x - y\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n (x_{ij} - y_{ij})^2}$$

刻画两个图像矩阵  $x, y \in \mathbb{R}^{m \times n}$  之间的距离.

- ▶ 第二项为 Tikhonov 正则项, 是对图像  $x$  的性质做出限制, 希望原始图像  $x$  的各个部分的变化不要太剧烈, 即水平和竖直方向的差分的平方和不要太大, 这种正则项会使得恢复的图像  $x$  具有比较好的光滑性.

模型(1)的目标函数是光滑的, 可以利用梯度法来求解. 目标函数  $f$  的梯度是

$$\nabla f(x) = x - y - 2\lambda\Delta x,$$

其中  $\Delta$  是图像  $x$  的离散拉普拉斯算子, 即

$$(\Delta x)_{ij} = \frac{x_{i+1,j} + x_{i-1,j} + x_{i,j+1} + x_{i,j-1} - 4x_{ij}}{h^2},$$

因此梯度法的迭代格式为

$$x^{k+1} = x^k - \alpha_k(I - 2\lambda\Delta)x^k + \alpha_k y$$

其中  $\alpha_k$  为步长.

---

**Algorithm 1:** 非单调线搜索的 BB 方法

---

- 1: 给定  $x^0$ , 选取初值  $\alpha > 0$ , 整数  $M \geq 0$ ,  $c_1, \beta, \varepsilon \in (0, 1)$ ,  $k = 0$ .
  - 2: **while**  $\|\nabla f(x^k)\| > \varepsilon$  **do**
  - 3:   **while**  $f(x^k - \alpha \nabla f(x^k)) \geq \max_{0 \leq j \leq \min\{k, M-1\}} f(x^{k-j}) - c_1 \alpha \|\nabla f(x^k)\|^2$   
      **do**
  - 4:     令  $\alpha \leftarrow \beta \alpha$ .
  - 5:   **end while**
  - 6:   令  $x^{k+1} = x^k - \alpha \nabla f(x^k)$ .
  - 7:   根据 BB 步长公式之一计算  $\alpha$ , 并做截断使得  $\alpha \in [\alpha_m, \alpha_M]$ .
  - 8:    $k \leftarrow k + 1$ .
  - 9: **end while**
-

**定义**(非单调线搜索, 见文献 (Zhang, Hager '04)) 设  $d^k$  是点  $x^k$  处的下降方向, 以下不等式可作为一种线搜索准则:


$$f(x^k + \alpha d^k) \leq C_k + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中  $C_k$  满足递推式  $C_0 = f(x^0)$ ,  $C_{k+1} = \frac{1}{Q_{k+1}} (\eta Q_k C_k + f(x^{k+1}))$ , 序列  $\{Q_k\}$  满足  $Q_0 = 1$ ,  $Q_{k+1} = \eta Q_k + 1$ , 参数  $\eta, c_1 \in (0, 1)$ .

这个非单调线搜索准则中的  $C_k$  是本次线搜索中的参照函数值, 做为本次迭代充分下降的起始标准; 而下一步的参照标准  $C_{k+1}$  则是函数值  $f(x^{k+1})$  和  $C_k$  的凸组合, 其中凸组合的系数由参数  $\eta$  决定. 当  $\eta = 0$  时, 此准则即为 Armijo 线搜索准则.



(a) The true one



(b) The noisy one



(c)  $\lambda = 0.5$



(d)  $\lambda = 2$

Figure: Tikhonov 正则化模型求解结果



图像去噪问题

LASSO 问题

逻辑回归问题

程序作业

考虑 LASSO 问题:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1,$$

其中  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$  且  $m < n$ .

- ▶ LASSO 问题的目标函数  $f(x)$  不光滑, 在某些点处无法求出梯度, 因此不能直接对原始问题使用梯度法求解
- ▶ 不光滑项为  $\|x\|_1$ , 它实际上是  $x$  各个分量绝对值的和, 考虑如下一维光滑函数:

$$l_\delta(x) = \begin{cases} \frac{1}{2\delta} x^2, & |x| < \delta, \\ |x| - \frac{\delta}{2}, & \text{其他.} \end{cases}$$

- ▶ 上述定义实际上是 Huber 损失函数的一种变形, 当  $\delta \rightarrow 0$  时, 光滑函数  $l_\delta(x)$  和绝对值函数  $|x|$  会越来越接近.

光滑化 LASSO 问题为

$$\min_{x \in \mathbb{R}^n} f_{\delta}(x) = \frac{1}{2} \|Ax - b\|^2 + \mu L_{\delta}(x), \quad (2)$$

其中  $L_{\delta}(x) = \sum_{i=1}^n l_{\delta}(x_i)$ ,  $\delta$  为给定的光滑化参数.




Figure: 当  $\delta$  取不同值时  $l_{\delta}(x)$  的图形

- ▶  $f_\delta(x)$  的梯度为

$$\nabla f_\delta(x) = A^T(Ax - b) + \mu \nabla L_\delta(x),$$

其中  $\nabla L_\delta(x)$  是逐个分量定义的:

$$(\nabla L_\delta(x))_i = \begin{cases} \text{sign}(x_i), & |x_i| > \delta, \\ \frac{x_i}{\delta}, & |x_i| \leq \delta. \end{cases}$$

- ▶  $f_\delta(x)$  的梯度是 Lipschitz 连续的, 其 Lipschitz 常数为  $L = \|A^T A\|_2 + \frac{\mu}{\delta}$ .
- ▶ 根据梯度法在凸函数上的收敛性定理, 固定步长需不超过  $\frac{1}{L}$  才能保证算法收敛, 如果  $\delta$  过小, 那么我们需要选取充分小的步长  $\alpha_k$  使得梯度法收敛.

在 Matlab 中可以按照如下方式生成 LASSO 模型中的  $A$  和  $b$  以及真实解  $x_{\text{orig}}$

```
m = 512; n = 1024;  
A = randn(m,n);  
xorig = sprandn(n, 1, r);  
b = A*xorig;
```

第二行生成一个稀疏向量  $x_{\text{orig}}$  做为真实解, 其中  $r \in (0, 1)$  是稀疏度, 即  $x_{\text{orig}}$  中非零元个数与总元素个数的比例为  $r$ .

也可以按照以下方式生成  $A, b$ :

```
I = randperm(n);  
J = I(1:k); %随机选定k个非零元素的位置  
xorig = zeros(n,1);  
xorig(J) = randn(k,1);  
A = randn(m,n);  
b = A*xorig;
```

**注:**LASSO 中  $m < n$

图像去噪问题

LASSO 问题

逻辑回归问题

程序作业

- 假设数据对  $\{a_i, b_i\}, i = 1, 2, \dots, m$  之间独立同分布, 则在给定  $a_1, a_2, \dots, a_m$  情况下,  $b_1, b_2, \dots, b_m$  的联合概率密度是

$$\begin{aligned} p(b_1, b_2, \dots, b_m \mid a_1, a_2, \dots, a_m; x) &= \prod_{i=1}^m p(b_i \mid a_i; x) \\ &= \frac{1}{\prod_{i=1}^m (1 + \exp(-b_i \cdot a_i^T x))}. \end{aligned}$$

- 最大似然估计是求解如下最优化问题:

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^m \ln(1 + \exp(-b_i \cdot a_i^T x)).$$

- 考虑加 Tikhonov 正则项的逻辑回归模型:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{m} \sum_{i=1}^m \ln(1 + \exp(-b_i a_i^T x)) + \mu \|x\|_2^2,$$

其中  $\mu > 0$  是正则化参数.

考虑如下光滑的无约束优化问题：

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{m} \sum_{i=1}^m \ln \left( 1 + \exp \left( -b_i a_i^T x \right) \right) + \mu \|x\|_2^2. \quad (3)$$

上述逻辑回归模型的目标函数是光滑的，可以使用梯度法求解。目标函数的梯度为

$$\begin{aligned} \nabla f(x) &= \frac{1}{m} \sum_{i=1}^m \frac{1}{1 + \exp(-b_i a_i^T x)} \cdot \exp(-b_i a_i^T x) \cdot (-b_i a_i) + 2\mu x \\ &= -\frac{1}{m} \sum_{i=1}^m (1 - p_i(x)) b_i a_i + 2\mu x, \end{aligned}$$

其中  $p_i(x) = \frac{1}{1 + \exp(-b_i a_i^T x)}$ .



引入矩阵  $A = [a_1, a_2, \dots, a_m]^T \in \mathbb{R}^{m \times n}$ , 向量  $b = (b_1, b_2, \dots, b_m)^T$ , 以及

$$p(x) = (p_1(x), p_2(x), \dots, p_m(x))^T,$$

则可重写梯度为

$$\nabla f(x) = -\frac{1}{m}A^T(b - b \odot p(x)) + 2\mu x \quad (4)$$

其中  $\odot$  指向量的点乘, 对于两个相同维数的向量  $a, b \in \mathbb{R}^m$

$$a \odot b = (a_1b_1, a_2b_2, \dots, a_mb_m)^T.$$

则梯度法迭代格式可以写作:

$$x^{k+1} = x^k + \alpha_k \left( \frac{1}{m}A^T(b - b \odot p(x^k)) - 2\mu x^k \right).$$

使用 `libsvmread` 导入数据集 `ijcnn1.test` 数据集, 用到的 `libsvmread.c` 文件和 `ijcnn1.test` 已上传在学习通资料中. 同时, 导入数据这部分代码已经写在 `demo_lr_gradient.m` 程序中.

由于 `libsvmread` 是一个 `.c` 文件, 需要在运行你的 Matlab 程序前进行如下额外操作使得形成一个 Matlab 可执行的文件:

- ▶ Matlab 路径设置为 `libsvmread.c` 所在的文件夹
- ▶ 在 Matlab 的 command window 运行如下代码行:

```
mex libsvmread.c
```

图像去噪问题

LASSO 问题

逻辑回归问题

程序作业

作业内容: 以下任务三选一

- ▶ 完成梯度法求解逻辑回归模型(3)的 Matlab 测试程序;
- ▶ 翻译图像去噪的 Matlab 程序为 Python 程序
- ▶ 用 Python 实现求解光滑化的 LASSO 模型(2)的梯度法; 其中线搜索使用非单调线搜索, BB 步长做为初始步长.

**注:** 此次程序作业满分 100; 选择编写逻辑回归模型 Matlab 测试程序 (第 1 个任务), 分数不高于 85 分; 选图像去噪的程序 (第 2 个任务) 翻译, 分数不高于 90;

**作业要求:** 需要写一个实验报告, 和程序打包上传学习通发布的分组任务.

- ▶ 写明程序运行环境：比如电脑操作系统，电脑配置参数等
- ▶ 写清楚用到的 Python 的工具包及其在程序中的主要用途
- ▶ 写明各个.py 文件的主要功能；写明每个.py 文件中各个模块实现的是优化算法中的什么步骤
- ▶ 要有实验结果分析：可以根据以下几点或者其他方面进行讨论
  - 对不同的模型参数 (逻辑回归中取  $\mu = 1e-1/m, 1e-2/m, 1e-3/m$ ；图像去噪中选  $\lambda = 0.5, 2, 5$ ；LASSO 中取  $\mu = 1e-2, 1e-3, 1e-4$ ，光滑参数  $\delta = 0.2, 1, 2$  等)；或者取不同终止准则，统计算法的迭代次数和运行时间
  - 每次迭代中非精确线搜索对应的内循环大概要多少步，BB 步长做为初始步长是否会被接受；非精确线搜索中函数参考值如果用 
$$\max_{0 \leq j \leq \min\{k, M-1\}} f(x^{k-j}),$$
迭代步数和运行时间会有什么变化；如果使用常数步长应该取步长为多大才能保证算法收敛，其迭代步数和运行时间相对线搜索的情况如何
  - 统计算法实现中最耗时的代码行，占整个运行时间的多少比例 (Matlab 中的可以用 profile 看到每一行代码被运行多少次及其总耗时)，根据 profile 考虑是否可以优化算法的效率
  - 记录每次迭代中目标函数的函数值和梯度的模，画出目标函数值和梯度随着迭代步数的变化图
  - LASSO 问题可以画出真实解和算法求出来的近似解的对比图；比如在同一个图中，用蓝色的 \* 画真实解，用红色的 o 画算法求得的近似解这样的方式